

Projekt címe: Sorsjegy-promóció Hatékonyság és Játékos-szegmentáció Analízis

A Projekt célja:

Egy fiktív, új kaparós sorsjegy bevezető kampányának elemzése. Meg kell határozni, hogy a promóció növelte-e a hosszú távú játékos kedvet, vagy csak egyszeri bevételt hozott.

1. Minta Adatbázis (300 soros logikai váz)

A projekt alapja három tábla, amit Excelben vagy SQL-ben kezelhető, 300 soros adatbázis.


Táblák:

1. **Dim_Jatekosok:** ID, Korcsoport, Regisztráció típusa (online/bolti), Szegmens.
2. **Fact_Tranzakciok:** ID, Játékos_ID, Dátum, Játék_típusa (pl. Sorsjegy, Tippmix), Összeg.
3. **Fact_Promociok:** Játékos_ID, Promóciós_kód_felhasználva (Igen/Nem), Nyeremény_visszaforgatva (Igen/Nem).

Módszertan: Power Query, Python, Power BI

2. Termékteljesítmény és Promóciós Hatás

A hisztogramon azt látjuk, hogy a promóciós kódok használata (**Igen** - világoskék) és elmaradása (**Nem** - sötétkék) hogyan oszlik meg játéktípusonként:




1.ábra

- **Sorsjegy, Lottó és Kenó:** Ezeknél a játékoknál a promóciós kódok használata egyértelműen magasabb bevételt generál. Különösen a Lottónál látszik, hogy a promóció nagy húzóerő. Ez azt jelenti, hogy ezek a játékosok "akcióérzékenyek", és a promóciók sikeresen növelik a forgalmat.

- **Tippmix – A kivétel:** Ez az egyetlen terület, ahol a **promóció nélküli bevétel jóval magasabb**. Ez arra utal, hogy a sportfogadók organikusabban játszanak (az események, meccsek miatt, nem a kuponokért), vagy a jelenlegi promóciós kódok nem találhatnak be ennél a célcsoportnál.

2. Csatornaeloszlás (Online vs. Lottózó)

A jobb alsó fáinkdiagram viszonylag kiegyensúlyozott képet mutat:




2.ábra

- **Lottózó (51,5%) vs. Online (48,5%):** Szinte hajszálpontos a fele-fele arány.

Bár a digitalizáció erős, a fizikai lottózók továbbra is a bevétel több mint felét adják. Ez egy stabil lábon álló üzleti modell, ahol egyik csatorna sem hanyagolható el.

3. KPI Mutatók és Időbeli Trend

- **Összes Bevétel (2 m):** A vizsgált időszakban elért 2 millió egységnyi bevétel stabil alap.



3.ábra

- **Promo_Impact (0,02):** Ez a mutató valószínűleg a promóciók által generált közvetlen növekményt vagy hatékonysági rátát jelzi. Bár a szám alacsonynak tűnik (2%), a diagramokon látott "Igen" oszlopok magassága alapján a promóciók mégis jelentős volumenért felelnek.




4.ábra

- **Időbeli lefutás:** A januári-februári grafikonon látszanak a tipikus "tűskék". Január 5. és 15. környékén komoly kiugrások vannak – ezek valószínűleg a hétvégi nagy sporteseményekhez vagy a lottósorsolások napjaihoz köthetők.

Stratégiai javaslatok a látottak alapján:

1. **Tippmix újragondolása:** Mivel itt a leggyengébb a promóciós kódok hatása, érdemes lenne a sportfogadóknak specifikusabb akciókat kínálni a sima kódok helyett.
2. **Sorsjegy fókusz:** A címben is szereplő sorsjegyeknél a promóció szemmel láthatóan remekül működik. Itt érdemes lehet növelni az akciók gyakoriságát, mert a közönség vevő rá.
3. **Online erősítés:** Mivel az online arány már majdnem 50%, egy célzott kampánnyal (pl. csak online beváltható kódokkal) át lehetne billenteni a mérleget a költséghatékonyabb digitális irányba.

Összességében a riport azt bizonyítja, hogy a **promóciók stabilan működnek a klasszikus szerencsejátékoknál**, de a sportfogadás terén még van kiaknázatlan lehetőség.



5.ábra

1. Kiemelt Üzleti Trendek (Felső sáv)

A. Termékek havi szezonalitása (Oszlopdiagram) Ez a grafikon megmutatja, hogy a különböző játéktípusok hogyan húzzák egymást, és mennyire függenek a szezonalitástól:

- Februárban a Tippmix bevétele jelentősen kilőtt (195 ezerre), miközben januárban sokkal alacsonyabb volt. *Üzleti magyarázat:* Ez tipikusan a Bajnokok Ligája tavaszi szezonjának indulása, vagy egy nagy nemzetközi sportesemény hatása. A sportfogadás nagyon eseményfüggő.
- Áprilisban a Kenó (világoskék) ugrott meg (200 ezerre). Mivel a Kenó amúgy egy stabil, lassú játék, egy ekkora ugrás szinte biztosan egy nagyon sikeres tavaszi marketingkampány vagy különsorsolás eredménye.
- A Sorsjegyek (narancs) hónapról hónapra a legkiegyensúlyozottabb teljesítményt nyújtják (161e, 125e, 171e, 147e). Ez a cég "fejőstehene", ami viszonylag kiszámítható bevételt hoz.

B. Demográfiai megoszlás (Fánkdiagram - Korcsoport)

- A diagramból látszik, hogy az **50+ korosztály (világoskék)** adja a legnagyobb szeletet a tortából. Ők a klasszikus lottózók és sorsjegyvásárlók.

2. Játékosbázis Értéke és Kockázata (Alsó sáv)

C. Kire épül az üzlet? (Fatérkép - Szegmensenkénti bevétel) Ez a klasszikus Pareto-elv (80/20 szabály) vizuális bizonyítéka.

- A **VIP szegmens (946 ezer)** és a **Rendszeres játékosok (848 ezer)** hozzák a bevétel majdnem 75%-át.
- Az Alkalmi játékosok (601 ezer) valószínűleg létszámban a legtöbbnek vannak, mégis ők hozzák a legkevesebb pénzt.
- *Üzleti döntés:* A marketingbüdzsé nagy részét a Rendszeres játékosok VIP-pé konvertálására, illetve a VIP-ek megtartására kell fordítani.

D. Lemorzsolódás megelőzése (Pontdiagram - Churn)

A bal oldali sűrű felhő (0-30 nap) jelenti a Fatérkép sötétkék és narancssárga dobozait (VIP és Rendszeres). Ők aktívak és pörgetik a pénzt.

A scatterplot grafikon szerint nincs olyan magas bevételt hozó játékos (VIP), aki már 80-100 napja nem játszott volna. Akik régen játszottak (jobb alsó sarok), azok feltehetően alacsony értékű, "Alkalmi" játékosok voltak.

Összefoglaló

A dashboard alapján az első negyedév stabil. A bevételeket egy nagyon erős VIP és Rendszeres mag biztosítja (ezt bizonyítja a Churn diagram). Ugyanakkor látjuk a termékek sérülékenységet: a Tippmix bevétele túlságosan eseményfüggő (februári kiugrás). A célzott stratégia az lenne, hogy az aktív, 50+ os korosztályban a sorsjegyek és a lottó mellett keresztértékesítéssel (cross-sell) erősítse a cég az online termékeket, hogy kisimuljon a havi bevételi ingadozás."

Elemzés Python kóddal

1. Leíró statisztika

	count	mean	std	min	25%	50%	75%	max
Promocios_kod_felhasznalva								
Igen	160.0	8060.41875	4031.083813	657.0	4758.25	8324.5	11595.25	14786.0
Nem	140.0	7901.90000	3764.591566	572.0	4696.00	7978.0	10959.00	14968.0

6. ábra

1. Mennyiségi eloszlás (Count)

- **Adat:** 160-an használtak kódot, 140-en nem.

A minta kiegyensúlyozott (közel 50-50%), ami statisztikailag megbízhatóbb összehasonlítást tesz lehetővé. Nem egy elszigetelt esetről beszélünk.

2. Átlagos teljesítmény (Mean)

- **Igen:** 8060.42
- **Nem:** 7901.90

A promóciós kódot használók átlagosan **~158.5 egységgel többet költöttek** (vagy termeltek), mint a többiek. Ez nagyjából **2%-os emelkedés**.

- **Üzleti kérdés:** Megérte a promóció? Ha a kód 5%-os kedvezményt adott, de csak 2% forgalomnövekedést hozott átlagban, akkor a cég veszített rajta. Ha viszont a kód ingyenes volt (pl. regisztráció ösztönző), akkor ez tiszta nyereség.

3. A szórás és a kockázat (Std)

- Mindkét csoportnál nagyon magas a szórás (~4000 körüli az 8000-es átlag mellett).

Az adatok nagyon szétszórtak. Vannak "kis" játékosok és "bálnák" (high rollers) is. A promóció nem tette "egyenletesebbé" a költést, a viselkedés ugyanolyan kiszámíthatatlan maradt.

4. Medián és Kvartilisek (50%, 75%)

Itt látszik az igazi különbség, amit az átlag elfed!

- **Medián (50%):** A kódosoknál 8324.5, a többieknél 7978. Ez jelentősebb különbség, mint az átlag! Azt mutatja, hogy a "közepű" játékos sokkal aktívabb volt a kóddal.
- **75% (Felső negyed):** A kódosok felső 25%-a 11 595 felett költött, míg a kód nélkülieknél ez csak 10 959.

A promóció leginkább a **felső-középréteget** mozgatta meg.

Az elemzés alapján a promóciós kód mérhető, de kismértékű növekedést hozott az átlagos forgalomban (kb. 2%). Ugyanakkor, ha a mediánt nézzük, látható egy határozottabb elmozdulás felfelé, ami azt jelenti, hogy a tipikus játékos többet költött a promóció hatására. Érdekes

megfigyelni, hogy bár a maximális költség a kód nélküli csoportban volt (14 968), a kódos csoport 75%-os kvartilise lényegesen magasabb. Ez arra utal, hogy a promóció sikeresen emelte meg a 'tömeg' költségi szintjét, még ha a rekordokat döntőgető egyéni játékosokra nem is volt hatással."

2. Classification Report

--- Predikciós Modell Jelentés ---				
	precision	recall	f1-score	support
0	0.69	0.80	0.74	60
1	0.40	0.27	0.32	30
accuracy			0.62	90
macro avg	0.54	0.53	0.53	90
weighted avg	0.59	0.62	0.60	90

7.ábra

1. Adatstruktúra és osztály-imbalansz

A vizsgált minta (N=90) bináris osztályozási feladatot reprezentál, ahol jelentős **osztály-imbalansz** figyelhető meg. A többségi osztály (0) a minta 66,7%-át teszi ki, míg a célosztály (1) alulreprezentált (33,3%). Ez a disztribúció eleve torzítja a globális pontossági mutatókat a többségi osztály irányába.

2. Osztályszintű metrikák elemzése

- **Szenzitivitás (Recall - Class 1):** A modell **Recall értéke szignifikánsan alacsony (0.27)** a célosztályra nézve. Statisztikai értelemben ez magas **Type II hibát** (hamis negatív) jelez: a releváns események 73%-át a modell nem képes azonosítani.
- **Precizitás (Precision - Class 1):** A **0.40-es érték** azt mutatja, hogy a pozitív predikciók több mint fele (60%) téves riasztás (**Type I hiba** / hamis pozitív).
- **F1-statisztika:** A célosztály harmonikus átlaga (**0.32**) jelzi a modell gyenge prediktív erejét a ritka események detektálásában.

3. Globális hatékonysági mutatók

- **Accuracy vs. Baseline:** A modell **0.62-es pontossága (Accuracy)** statisztikai értelemben **negatív hozzáadott értéket képvisel**. Mivel a többségi osztály aránya 66,7%, egy naiv osztályozó (mely mindenre 0-t tippel) 66,7%-os pontosságot érne el. A modell tehát nem teljesíti felül az alapszintű véletlen/naiv becslést.
- **Macro vs. Weighted Average:** A **Macro F1 (0.53)** és a **Weighted F1 (0.60)** közötti eltérés igazolja, hogy a modell teljesítményét a többségi osztály (Class 0) viszonylag stabilabb predikciója javítja fel mesterségesen.

4. Módszertani konklúzió

A modell jelenlegi állapotában **statisztikailag nem szignifikáns** üzleti döntéshozatalhoz. A magas Type II hibaarány alkalmatlanná teszi kockázatbecslésre vagy lemorzsolódás-előrejelzésre.

Javaolt korrekciós lépések:

1. **Resampling stratégiák:** Over-sampling (SMOTE) vagy Under-sampling alkalmazása az osztály-imbalansz kezelésére.
2. **Cost-sensitive learning:** A célosztály elvétéséhez (hamis negatív) rendelt büntetőfüggvény növelése a tanítás során.
3. **Feature Engineering:** További prediktív változók bevonása a modell diszkriminációs képességének javítására.

2.Független kétmintás t-próba

Ez a Python kód és annak kimenete egy **független kétmintás t-próba (independent t-test)** lefuttatását és kiértékelését mutatja be. Ez a statisztikai eljárás arra hivatott, hogy eldöntse: a két vizsgált csoport (kuponos vs. kontroll) átlagai közötti eltérés a véletlen műve, vagy valódi hatás áll mögötte.

```
T-statisztika: 0.3504
P-érték: 0.7263
Insight: A különbség statisztikailag nem szignifikáns (p > 0.05).
```

8.ábra

1. Hipotézis keretrendszer

- **Nullhipotézis (H_0):** Nincs statisztikailag kimutatható különbség a kuponkódot felhasználók és a kontrollcsoport átlagos költsége (összege) között ($\mu_1 = \mu_2$).
- **Ellenhipotézis (H_a):** Létezik szignifikáns különbség a két csoport átlagos költsége között ($\mu_1 \neq \mu_2$).

2. A tesztmutatók értelmezése

- **T-statisztika (0,3504):** Ez az érték rendkívül alacsony. Azt jelzi, hogy a csoportok átlagai közötti különbség nagyon kicsi a mintán belüli szóráshoz (varianciához) képest. Minél közelebb van a nullához, annál valószínűbb, hogy a két csoport azonos eloszlásból származik.
- **P-érték (0,7263):** A statisztikai szignifikancia általánosan elfogadott küszöbértéke $\alpha = 0,05$. Mivel a kapott $p = 0,7263$, ami jóval nagyobb, mint $0,05$, **nem tudjuk elvetni a nullhipotézist**.

3. Statisztikai konklúzió

A teszt eredménye alapján a különbség **statisztikailag nem szignifikáns**. Ez azt jelenti, hogy bár a korábbi leíró statisztikában láttunk némi eltérést az átlagok között (a korábbi táblázatban

~2%-ot), ez az eltérés nem elég nagy vagy nem elég következetes ahhoz, hogy kijelenthessük: a promóciós kód valódi hatást gyakorolt a költési hajlandóságra.

A megfigyelt kismértékű átlageltérés nagy valószínűséggel csak a **mintavételi ingadozás (véletlen)** eredménye, nem pedig a promóció tényleges következménye.

4. Üzleti javaslat

- **Mintaelemszám növelése:** Ha a hatásméret (effect size) kicsi, előfordulhat, hogy csak sokkal nagyobb mintán (több ezer soron) válna szignifikánssá a különbség.
- **Szegmentált vizsgálat:** Érdeemes lenne megvizsgálni, hogy bizonyos szubpopulációkban (pl. csak az új játékosoknál vagy csak egy bizonyos játéktípusnál) megfigyelhető-e szignifikáns elmozdulás.
- **Mechanizmus váltás:** Mivel a jelenlegi promóciós kód "nem mozgatja meg a tűt" statisztikai értelemben, javasolt a promóció típusának (pl. bónusz összege, feltételek) újratervezése.

Jupyter Notebook file_ SZERENCSEJATEK2.ipynb

A projekt kidolgozása során AI-alapú asszisztenciát vettem igénybe a munkafolyamatok automatizálására és a statisztikai kódok validálására.